


基本思想

采用自顶向下的递归方法，构造一棵由结点和有向边组成的树，每个叶节点中的实例都属于同一类。



知乎 @简博士

分类依据

ID3算法：信息增益

- 以信息熵为度量，用于决策树节点的属性选择，每次优先选取信息增益最大的属性，亦即使熵值变为最小的属性，以构造一颗熵值下降最快的决策树，到叶子节点处的熵值为0。此时，每个叶子节点对应的实例集中的实例属于同一类。
- 熵表示随机变量不确定性的度量，是度量样本集合纯度最常用的一种指标，熵定义了概率密度函数到一个值的映射 p 。
- 信息量：具有确定概率事件的信息的定量度量， $I(x) = -\log_2 p(x)$ 。
- 信息熵：事件集合的信息量的平均值， $H(x) = -\sum_i p(x_i) \log_2 p(x_i)$ 。
- 经验信息熵： $H(D) = -\sum_{i=1}^C \frac{|D_c|}{|D|} \log_2 \frac{|D_c|}{|D|}$ 。
- 条件熵： $H(Y | X)$ 表示在已知随机变量 X 的条件下，随机变量 Y 的不确定性， $H(Y | X) = -\sum_{i=1}^n p_i H(Y | X = x_i) = H(X, Y) - H(X)$ 。
- 经验条件熵： $H(D | a) = \sum_{i=1}^N \frac{|D^n|}{|D|} H(D^n)$ 。
- 信息增益： $G(D, a) = H(D) - \sum_{n=1}^N \frac{|D^n|}{|D|} H(D^n)$ 。
- 从一类无序、无规则的事物概念中推理出决策树表示的分类规则，属于有监督学习。

- 信息增益偏好取值多的属性，可能会受噪声或小样本影响，易出现过拟合问题，无法处理连续值的属性，无法处理属性值不完整的训练数据，无法处理不同代价的属性。

C4.5算法：信息增益率

- $G_{ratio}(D, a) = \frac{G(D, a)}{H(a)}$ ，缓解信息增益准则对可取值数目较多的属性的偏好。

CART算法：基尼指数

- $Gini(D) = 1 - \sum_{c=1}^C p_c^2 = 1 - \sum_{c=1}^C \left(\frac{|D_c|}{|D|} \right)^2$
- 直观反映了从数据集中随机抽取两个样本，其类别不一致的概率；因此，Gini(D)越小，则数据集D的纯度越高
- $Gini(D, a) = \sum_{n=1}^N \frac{|D^n|}{|D|} Gini(D^n)$
- $a^* = \arg \min_{a \in A} Gini(D, a)$

剪枝策略

泛化性能：指模型对未知数据的预测能力，是评估机器学习模型好坏的核心指标，常用训练集的正确分类比作为衡量标准。良好的泛化性能意味着模型不仅能在训练数据上表现良好，更能准确预测未见过的数据。

预剪枝

在决策树生成过程中，对每个节点划分前进行估计，若不能提升泛化性能则停止划分，设为叶节点

- **优势**：减少过拟合风险，显著降低训练和测试时间开销
- **劣势**：可能因禁止后续有益划分而导致欠拟合

后剪枝

先生成完整决策树，再自底向上考察非叶节点，若替换为叶节点能提升泛化性能则替换

- **优势**：保留更多分支，降低欠拟合风险，泛化性能通常优于预剪枝
- **劣势**：训练时间长，需在生成完整树后自底向上评估

连续值处理

离散化

采用二分法进行离散化，分别计算候选划分点集合中每一个划分点对应的信息增益，然后选择信息增益最大至对应的 t 作为决策树划分点

$$T_a = \left\{ \frac{a_n + a_{n+1}}{2} \mid 1 \leq n \leq N - 1 \right\}$$

- T_a ：表示候选划分点的集合
- a_n ：表示序列中的第n个元素（要求序列已按升序排列： $a_1 \leq a_2 \leq \dots \leq a_N$ ）
- $\frac{a_n + a_{n+1}}{2}$ ：计算相邻两个元素的平均值作为候选划分点
- $1 \leq n \leq N - 1$ ：n的取值范围，表示对序列中所有相邻元素对进行计算

信息增益

$$G(D, a) = \max_{t \in T_a} G(D, a, t)$$
$$= \max_{t \in T_a} \left(H(D) - \sum_{\lambda \in \{+, -\}} \frac{|D_t^\lambda|}{|D|} H(D_t^\lambda) \right)$$

- $G(D, a, t)$: 样本集D基于划分点t二分后的信息增益
- $H(D)$: 样本集D的经验信息熵（原始不确定性）
- $\lambda \in \{+, -\}$: 划分后的两个子集（大于划分点t和小于等于划分点t）
- $\frac{|D_t^\lambda|}{|D|}$: 各子集样本数占总样本数的比例
- $H(D_t^\lambda)$: 各子集的经验信息熵

缺失值处理

信息增益计算

仅利用没有属性缺失的样本

$$G(D, a) = \rho G(\tilde{D}, a)$$

- ρ : 无缺失值样本占总样本的比例
- $\tilde{D}$: 表示在属性a上没有缺失值的样本子集

含有缺失属性的样本的划分

- 若样本x在属性a上的取值已知：将x划入与其取值对应的子节点，且样本权值保持为 w_x
- 若样本x在属性a上的取值未知：将x划入所有子节点，且其在与属性值 a_n 对应的子节点中的权值调整为 $\tilde{r}_n \cdot w_x$

不同代价属性的处理

线性归一化

$$G_{Cost}(D, a) = \frac{G(D, a)}{Cost(a)}$$

指数归一化

$$G_{Cost}(D, a) = \frac{2^{G(D, a)} - 1}{(Cost(a) + 1)^w}$$

参数说明：

- $Cost(a)$: 属性a的采集代价
- w : 调节参数，用于控制代价对增益影响的强度（ $w \in [0, 1]$ ）
- 两种方法都是将传统信息增益与属性代价相结合，倾向于选择增益高且代价低的属性

例题1

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

计算信息增益 (以色泽为例)

$$H(D) = -\sum_{c=1}^C p_c \log_2 p_c = -\left(\frac{8}{17} \log_2 \frac{8}{17} + \frac{9}{17} \log_2 \frac{9}{17}\right) = 0.998$$

编号	色泽	好瓜
1	青绿	是
2	乌黑	是
3	乌黑	是
4	青绿	是
5	浅白	是
6	青绿	是
7	乌黑	是
8	乌黑	是
9	乌黑	否
10	青绿	否
11	浅白	否
12	浅白	否
13	青绿	否
14	浅白	否
15	乌黑	否
16	浅白	否
17	青绿	否

$$H(D^{青绿}) = -\left(\frac{3}{6} \log_2 \frac{3}{6} + \frac{3}{6} \log_2 \frac{3}{6}\right) = 1.000$$

$$H(D^{乌黑}) = -\left(\frac{4}{6} \log_2 \frac{4}{6} + \frac{2}{6} \log_2 \frac{2}{6}\right) = 0.918$$

$$H(D^{浅白}) = -\left(\frac{1}{5} \log_2 \frac{1}{5} + \frac{4}{5} \log_2 \frac{4}{5}\right) = 0.722$$

$$\begin{aligned} G(D, \text{色泽}) &= H(D) - \sum_{n=1}^3 \frac{|D^n|}{|D|} H(D^n) \\ &= 0.998 - \left(\frac{6}{17} \times 1.000 + \frac{6}{17} \times 0.918 + \frac{5}{17} \times 0.722\right) \\ &= 0.109 \end{aligned}$$

■ $G(D, \text{色泽}) = 0.109$

■ $G(D, \text{敲声}) = 0.141$

■ $G(D, \text{脐部}) = 0.289$

$G(D, \text{根蒂}) = 0.143$

$G(D, \text{纹理}) = 0.381$

$G(D, \text{触感}) = 0.006$

继续进行划分-以“纹理=清晰”分支为例

■ “纹理=清晰”分支：

样本 {1,2,3,4,5,6,8,10,15}

■ 计算信息增益

● $G(D^{\text{清晰}}, \text{色泽}) = 0.043$


● $G(D^{\text{清晰}}, \text{敲声}) = 0.331$

● $G(D^{\text{清晰}}, \text{触感}) = 0.458$

$G(D^{\text{清晰}}, \text{根蒂}) = 0.458$

$G(D^{\text{清晰}}, \text{脐部}) = 0.458$

● 最终生成的决策树



例题2

【例题】用ID3算法对下面的数据集进行分类，根据星球的大小和轨道判断其是否宜居：

数量	大小	轨道	是否宜居
30	大	远	是
130	大	近	是
48	小	远	是
161	小	近	是
20	大	远	否
170	大	近	否
11	小	远	否
230	小	近	否

1. 以分类目标为样本，计算总体信息熵：

$$P(\text{宜居}) = \frac{369}{800}, P(\text{不宜居}) = \frac{431}{800}$$

熵：

$$H_{\text{总体}} = -(P(\text{宜居})\log_2(P(\text{宜居})) + P(\text{不宜居})\log_2(P(\text{不宜居}))) = 0.9957$$

2. 计算属性：大小的信息增益：

i. 大小-大：

$$P(\text{宜居}|\text{大}) = \frac{160}{350}, P(\text{不宜居}|\text{大}) = \frac{190}{350}$$

$$H_{\text{大}} = 0.9947$$

ii. 大小-小：

$$P(\text{宜居}|\text{小}) = \frac{209}{450}, P(\text{不宜居}|\text{小}) = \frac{241}{450}$$

$$H_{\text{小}} = 0.9963$$

期望信息熵为：

$$H_{\text{大小}} = P(\text{大})H_{\text{大}} + P(\text{小})H_{\text{小}} = 0.9956$$

信息增益

$$G_{\text{大小}} = H_{\text{总}} - H_{\text{大小}} = 0.001$$

3. 计算属性：轨道的信息增益

i. 轨道-近：

$$P(\text{宜居}|\text{近}) = \frac{291}{691}, P(\text{不宜居}|\text{近}) = \frac{400}{691}$$

$$H_{\text{近}} = 0.9820$$

ii. 轨道-远：

$$P(\text{宜居}|\text{远}) = \frac{78}{109}, P(\text{不宜居}|\text{远}) = \frac{31}{109}$$

$$H_{\text{远}} = 0.8614$$


期望信息熵为：

$$H_{\text{轨道}} = P(\text{近})H_{\text{近}} + P(\text{远})H_{\text{远}} = 0.9656$$

信息增益

$$G_{\text{轨道}} = 0.0301$$

4. 所以，第一个结点为「轨道」：



5. 计算子树T1

因为

$$P(\text{宜居}|\text{大,近}) < P(\text{不宜居}|\text{大,近})$$

$$P(\text{宜居}|\text{小,近}) < P(\text{不宜居}|\text{小,近})$$


所以T₁为叶结点，置为「不宜居」

6. 计算子树T₂

$$P(\text{宜居}|\text{大,远}) > P(\text{不宜居}|\text{大,远})$$

$$P(\text{宜居}|\text{小,远}) > P(\text{不宜居}|\text{小,远})$$

所以T₂为叶结点，置为「宜居」



例题3

使用 CART 算法

	是否用鳃呼吸	有无鱼鳍	是否为鱼
0	是	有	是
1	是	有	是
2	是	无	否
3	否	有	否
4	否	有	否

$$Gini(D, A_1) = \frac{3}{5} [1 - [(\frac{2}{3})^2 + (\frac{1}{3})^2]] + \frac{2}{5} [1 - 1] = 0.2$$

$$Gini(D, A_2) = \frac{4}{5} \{1 - [(\frac{1}{2})^2 + (\frac{1}{2})^2]\} + \frac{1}{5} (1 - 1) = 0.40$$