

基本概念

监督学习

需要大量已标记的训练样本，大规模人工标注耗时、难度大、代价高（隐私、安全），标注数据通用性较弱，但未标注数据很容易获得，但未利用。

无监督学习

无已标记（监督信息）样本，基于未标注样本间的相似度，对样本进行类别归纳，如聚类 and 降维，但无监督学习完全基于无标记样本学习，精度难以保证，且未利用有可能有的少量有标记样本。

基本假设

聚类假设

- 数据存在簇结构，同一簇的样本属于同一类别
- 处在相同聚类中的样本有较大可能拥有相同标记
- 决策边界应尽量通过数据较稀疏的地方，避免把稠密聚类中的数据分到决策边界两侧
- 大量未标记样本的作用就是帮助探明样本空间中数据分布的稠密和稀疏区域，指导对决策边界进行调整

流形假设（局部）

- 数据分布在一个流形结构上，邻近样本有相似输出值
- 流形：局部具有欧几里得空间性质的空间
- 处于很小局部区域内的样本有相似性质，因此标记也相似
- 和聚类假设着眼整体特性不同，流形假设主要考虑模型的局部特性，反映决策函数的局部平滑性
- 大量未标记示例的作用就是让数据空间变得更加稠密，从而有助于更加准确地刻画局部区域的特性，使得决策函数能够更好地进行数据拟合
- 可看做是聚类假设的推广，对输出值没有限制（可以是相近的连续值），应用更广泛

学习算法分类

直推学习

封闭世界假设，仅试图对学习过程中观察到的未标记样本进行预测。

纯半监督学习

开放世界假设，学得模型能适用于训练过程中未观察到的未标记数据进行预测。

监督学习算法分类

自学习方法

分类器递归拟合时，每次递归仅将满足设定置信度阈值，即置信度高的样本纳入已标记样本集中，参与递归拟合。

半监督SVM

- S3VM 是标准 SVM 方法在未标记样本上的一种推广，其中直推式支持向量机 T-SVM 是最典型的算法
- 基本思想：针对二分类问题，同时利用标记和未标记样本，通过尝试将每个未标记样本分别作为正例和反例来寻找最优分类边界，来得到原始数据中两类样本的最大分类间隔（最小错误率），即寻找穿过数据低密度分布区域的分类面

优化问题

$$\min_{w,b,\hat{y},\xi} \frac{1}{2} \|w\|_2^2 + C_l \sum_{i=1}^l \xi_i + C_u \sum_{i=l+1}^m \xi_i$$

约束条件：

- $y_i (w^\top x_i + b) \geq 1 - \xi_i, \quad i = 1, \dots, l$
- $\hat{y}_i (w^\top x_i + b) \geq 1 - \xi_i, \quad i = l + 1, \dots, m$
- $\xi_i \geq 0, \quad i = 1, \dots, m$

其中 C_l 和 C_u 分别表示已标记样本和未标记样本的惩罚因子，用于调整不同样本的权重。

求解方法

- 尝试未标记样本的各种标记指派是一个穷举遍历过程，未标记样本数太大时不能直接求解
- 采用局部搜索迭代求近似解，通过局部搜索和调整指派为异类且可能错误的标记指派，使目标函数值不断下降
- 局部搜索 x_i, x_j ，将两者指派为不同标签，求解对应超平面和松弛变量，如果 $\xi_i + \xi_j > 2$ ，证明可能错误，互换标记再次求解
- 初始时未标记样本的伪标记不准确，对应的 C_u 系数要小，逐渐增大 C_u 提高未标记样本贡献
- 搜寻标记指派出错的每一对未标记样本并进行调整，是一个复杂的大规模优化问题

半监督聚类

第一种类型：必连与勿连约束

- 必连约束：样本必属于同一个簇
- 勿连约束：样本必不属于同一个簇

约束K均值算法

- 该算法是K均值算法的扩展
- 在聚类过程中要确保必连关系集合与勿连关系集合中的约束得以满足，否则将返回错误提示
- 如果不冲突，那么将点划分近最近的簇，否则，再尝试次近的簇

第二种类型：少量有标记样本

约束种子K均值算法

- 假设少量有标记样本属于K个聚类簇，直接将它们作为种子
- 用它们初始化K均值算法的K个聚类中心
- 在聚类簇迭代更新过程中，不改变种子样本的簇隶属关系

算法局限性

抗干扰性较弱

- 现有算法多针对无噪声干扰样本数据，而实际数据通常存在噪声干扰
- 需综合考虑噪声干扰下未标记样本数据分布的不确定性及复杂性