

1. 最优分类面：要求分类线不但能将两类正确分开，且使分类间隔最大。SVM考虑寻找一个满足分类要求的超平面，并且使训练集中的点距离分类面尽可能的远，也就是寻找一个分类面使它两侧的空白区域最大

2. 支持向量机：

- 样本集任意一点到分类面的距离 $\frac{t_n(w^T x_n + b)}{\|w\|}$ ，且 $t_n y(x_n) > 0$
- 优化w和b使空白区域最大， $\arg \max_{w,b} \left\{ \frac{1}{\|w\|} \min_n [t_n(w^T x_n + b)] \right\}$
- $w \rightarrow kw, b \rightarrow kb$ ，对于离超平面最近的点 $t_n(w^T x_n + b) = 1$ ，那么所有点大于等于1
- 原问题转化为二次规划问题 $\min_{w,b} \frac{1}{2} \|w\|^2 \text{ s.t. } t_n(w^T x_n + b) \geq 1$
- 使用拉格朗日乘子法将上述二次规划问题转化为等价的对偶问题进行简化求解：

$$L(w, b, a) = \frac{1}{2} \|w\|^2 - \sum_{n=1}^N a_n \{t_n(w^T x_n + b) - 1\}$$
- 拉格朗日求极值： $\max_a \sum_{n=1}^N a_n - \frac{1}{2} (\sum_{n=1}^N a_n t_n x_n)^2$
- s.t. $a_n \geq 0, n = 1, \dots, N, \sum_{n=1}^N a_n t_n = 0$
- 得到超平面为： $y(x) = \sum_{n=1}^N a_n t_n x_n^T x + b, b = \frac{1}{N_S} \sum_{n \in S} (t_n - \sum_{m \in S} a_m t_m x_n^T x_m)$
- KKT条件
 - 拉格朗日梯度条件：梯度为0
 - 互补松弛条件：最优解处，若某个不等式约束未起作用，则其对应的乘子为0；若乘子大于0，则约束必须严格起作用
 - 对偶可行性：不等式约束对应的拉格朗日乘子非负
 - 原问题可行性：约束条件本身在最优解处成立
- 支持向量： $t_n(w^T x + b) = 1, a_n > 0$
- 非支持向量： $t_n(w^T x + b) > 1, a_n = 0$
- 只有支持向量决定分类超平面，非支持向量与其无关
- 由于样本中不可避免地存在噪声和离群点，可能导致硬间隔求解的最优分类面泛化性能差

3. 软间隔：

- $t_n y(x_n) \geq 1 - \xi_n$
- 优化： $\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{n=1}^N \xi_n \text{ s.t. } t_n(w^T x_n + b) \geq 1 - \xi_n, \xi_n \geq 0$
- 对偶问题： $\max_a \sum_{n=1}^N a_n - \frac{1}{2} (\sum_{n=1}^N a_n t_n x_n)^2$
- s.t. $0 \leq a_n \leq C, n = 1, \dots, N, \sum_{n=1}^N a_n t_n = 0$
- 支持向量： $t_n(w^T x + b) - 1 + \xi_n = 0, a_n > 0, \mu_n \xi_n = 0$
- 非支持向量： $a_n = 0$ ，样本 x_n 不受约束
- $a_n < C, \mu_n > 0, \xi_n = 0$ 样本 x_n 在最大分隔边界上
- $a_n = C, \mu_n = 0, u_n$ 不再约束 ξ_n
 - $\xi_n \leq 1$ 样本 x_n 在最大分隔内且未被错分
 - $\xi_n > 1$ 样本 x_n 被错分

	软间隔	硬间隔
允许错分	允许对噪声/离群点有一定错分	不允许错分
间隔与泛化	最大间隔更大，泛化性更好	最大间隔小，泛化性差
优化目标	含惩罚项（超参 C 及求和项）	无惩罚项
求解难度	含超参，求解较复杂	求解过程较简单
综合特点	权衡泛化性和准确性的综合选择	准确性高，泛化性差

4. 非线性支持向量机：把样本 x 映射到某个高维特征空间，并在其中使用线性分类器，利用一个固定的非线性映射将数据映射到特征空间学习的线性分类器等价于基于原始数据学习的非线性分类器

5. 核函数：在特征空间中直接计算数据映射后的内积，就像在原始输入数据的函数中计算一样，大大简化了计算过程，直接在原来的低维空间中进行计算不需要显式地写出映射后的结果，避免了先映射到高维空间中然后再根据内积的公式进行计算

6. 序列最小优化算法

- 支持向量机的学习问题可以形式化为求解具有全局最优解的凸二次规划问题。许多方法可以用于求解这一问题，但当训练样本容量很大时，这些算法往往效率较低，以致无法使用。
- 思想：如果所有变量都满足此优化问题的KKT条件，那么这个问题的解就得到了
- 特点：不断地将原二次规划问题分解为只有两个变量的二次规划问题，并对子问题进行解析求解，直到所有变量都满足KKT条件为止。因为子问题解析解存在，所以每次计算子问题都很快

例题

【讲解】支持向量机的考法一般是让你简述一下原理，然后问一下软间隔和核函数。

【例题】svm的基本思想，模型表达式，软间隔和硬间隔的物理含义，如何用来解决非线性问题

【解答】对于分类问题：在空间中找一个超平面，最大化地分开不同数据点。对于样本 $\{\mathbf{x}_i, t_i\}$ ，其中 $\mathbf{x}_i$ 是空间中的点， $t_i \in \{-1, 1\}$ 是标签。找一个分类器 $y = \mathbf{w}^T \mathbf{x} + b$ ，使得：

$$t_i = \begin{cases} 1, & y(\mathbf{x}_i) > 0 \\ -1 & y(\mathbf{x}_i) < 0 \end{cases}$$

SVM的思想是，寻找一个超平面，使其两端的空白区最大，即：

$$\begin{aligned} & \text{maximize}_{\mathbf{w}, b} \quad \frac{1}{\|\mathbf{w}\|} |\mathbf{w}^T \mathbf{x}_i + b_i| \\ & s. t. \quad t_i (\mathbf{w}_i^T \mathbf{x}_i + b_i) \geq 1 \end{aligned}$$

问题等价为：

$$\begin{aligned} & \text{minimize}_{\mathbf{w}, b} \quad \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ & s. t. \quad t_i (\mathbf{w}_i^T \mathbf{x}_i + b_i) \geq 1 \end{aligned}$$

这就是SVM的基本型。利用拉格朗日乘法法的对偶问题，可以写出其对偶型

$$\begin{aligned} & \text{minimize}_{\alpha} \quad \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j t_i t_j \mathbf{x}_i^T \mathbf{x}_j - \sum_{i=1}^N \alpha_i \\ & s. t. \quad \alpha > 0 \\ & \quad \sum_{i=1}^N \alpha_i t_i = 0 \end{aligned}$$

核技巧是应对非线性可分问题的一种方法。在 $\mathbb{R}^d$ 中，如果 $\{\mathbf{x}_i, t_i\}$ 不是线性可分的，则必定存在一个映射 $\phi: \mathbb{R}^d \rightarrow \mathbb{R}^{d'}$ ，使得 $\{\phi(\mathbf{x}_i), t_i\}$ 在 $\mathbb{R}^{d'}$ 中是线性可分的，其中一般有 $d' \geq d$ 。此时，SVM的对偶问题变为：

$$\begin{aligned} & \text{minimize}_{\alpha} \quad \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j t_i t_j \phi^T(\mathbf{x}_i) \phi(\mathbf{x}_j) - \sum_{i=1}^N \alpha_i \\ & s. t. \quad \alpha > 0 \\ & \quad \sum_{i=1}^N \alpha_i t_i = 0 \end{aligned}$$

所谓的核技巧，就是寻找一个函数 $k(\mathbf{x}_i, \mathbf{x}_j)$ ，使得

$$k(\mathbf{x}_i, \mathbf{x}_j) = \phi^T(\mathbf{x}_i) \phi(\mathbf{x}_j)$$

且计算 k 的复杂度是 d ，这样就能够加速计算。常用的核有：

1. 线性核： $k = x_i^T x_j$, $d \rightarrow d$
2. 多项式核： $k = (\gamma x_i^T x_j + c)^k$, $d \rightarrow C_k^{d+k}$
3. 高斯核： $k = \exp(-\gamma \|x_i - x_j\|^2)$, $d \rightarrow \infty$

还有一种线性不可分是数据噪声造成的，这时可以用软间隔法。对于每一个样本引入一个松弛变量 ϵ ，原始问题变成：

$$\begin{aligned} \text{minimize}_{w,b} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{s.t.} \quad & t_i (\mathbf{w}_i^T \mathbf{x}_i + b_i) \geq 1 - \epsilon_i \end{aligned}$$

对偶问题变成：

$$\begin{aligned} \text{minimize}_{\alpha} \quad & \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j t_i t_j \phi^T(\mathbf{x}_i) \phi(\mathbf{x}_j) - \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad & \alpha \in (0, C) \\ & \sum_{i=1}^N \alpha_i t_i = 0 \end{aligned}$$