

降维

在原始的高维空间中，包含冗余信息和噪声信息，会在实验应用中引入误差，影响准确率；而降维可以提取数据内部的本质结构，减少冗余信息和噪声信息造成的误差，提高应用中的精度。

主成分分析 (PCA)

将原有众多具有相关性的指标重新组合成一定量互相无关的综合指标，使得降维后样本的方差尽可能大，使得降维后数据的均方误差尽可能小。

最大方差思想

- **核心目标**：使用较少的数据维度保留住较多的原数据特征
- **单维度投影**：首先考虑 $M=1$ ，定义这个空间的投影方向为 D 维向量 u_1 ，设 $u_1^T u_1 = 1$
- **投影方差计算**：投影后样本方差表示为 $\frac{1}{N} \sum_{i=1}^N u_{1i}^T (x_n - u_i^T x) = u_1^T S u_1$
- **样本方差矩阵**：其中原样本方差 $S = \frac{1}{N} (x_n - \bar{x})(x_n - \bar{x})^T$
- **优化求解**：目标是最大化投影后样本方差，利用拉格朗日乘子法得 u_1 是 S 的拓展向量， u_1 是 S 的最大特征值对应的特征向量时方差提取到最大值
- **多维扩展**：考虑更一般性的情况，新空间中数据的最大主成分的最佳投影方向由协方差矩阵 S 的 M 个特征向量定义，其分别对应 M 个最大的特征值
- **迭代过程**：首先获得样本最大的1维，生成该维的补空间；继续在补空间中获得方差最大的1维，生成新的补空间；依次循环下去得到 M 维的空间

最小均方误差思想

- **核心目标**：使用数据与降维后的数据（在原空间中的重建）的误差最小
- **正交基表示**：定义一组 D 个正交的 D 维向量，且 $u_1^T u_1 = \delta_{ij}$ ，那么 $x_n = \sum_{i=1}^N (x_{n,i}^T u_i) u_i$
- **降维表示**：在 M 维变量生成的空间中进行表示， $\tilde{x}_n = \sum_{i=1}^N z_{n,i} u_i + \sum_{i=M+1}^{M-1} b_i u_i$
- **误差最小化**：目标最小化 $J = \frac{1}{N} \sum_{i=1}^N |x_n - \tilde{x}_n|$
- **求解结果**：求导结果同最大方差思想，对应失真度为 $J = \sum_{i=M+1}^D \lambda_i$
- **最优选择**：最小时取 $D-M$ 个最小的特征值，主子空间对应 M 个最大特征值

PCA的优缺点

优点

- 具有很高普适性，最大程度地保持了原有数据的信息
- 可对主元的重要性进行排序并根据需要略去部分维数，达到降维从而简化模型或对数据进行压缩的效果
- 完全无参数限制，在计算过程中不需要人为设定参数或是根据任何经验模型对计算进行干预，最终结果只与数据相关

局限性

- 假设模型是线性的，也就决定了它能进行的主元分析之间的关系也是线性的
- 假设数据具有较高信噪比，具有最高方差的一维向量被看作是主元，而方差较小的变化被认为是噪声

PCA与LDA (Fisher准则) 比较

- **PCA**: 追求降维后能够最大化保持数据内在信息，并通过衡量在投影方向上的数据方差来判断其重要性。但这对数据的区分作用并不大，反而可能使得数据点混杂在一起
- **LDA**: 所追求的目标与PCA不同，不是希望保持数据最多的信息，而是希望数据在降维后能够很容易地被区分开

Kernel PCA

将主成分分析的线性假设一般化使之适应非线性数据

等距映射 (ISO-Metric Mapping)

保持数据点内在几何性质 (测地距离)

算法步骤

1. **构造临近关系图**: 对每一个点，将它与指定半径邻域内所有点相连或与指定个数最近邻相连
2. **计算最短路径**: 计算临近关系图所有点对之间的最短路径，得到距离矩阵
3. **多尺度分析**: 将高维空间中的数据点投影到低维空间，使投影前后的距离矩阵相似度最大
4. **特征求解**: 求矩阵 $L = -\frac{1}{2} H S H$ 的特征值和特征向量，其中H是中心矩阵，S是距离矩阵的平方

优缺点

- **优点**: 非线性、非迭代、全局最优、参数可调节
- **缺点**: 容易受噪声干扰、在大曲率区域存在短路现象、不适用于非凸参数空间、大样本训练速度慢

局部线性嵌入

保持数据点的原有流形结构

基本假设

采样数据所在的低维流形在局部是线性的，每个采样点可以用它的近邻点线性表示

学习目标

在低维空间中保持每个邻域中的权值不变，即假设嵌入映射在局部是线性的条件下，最小化重构误差

算法实现

对每个点用K个近邻进行重建，确定一组权值 w_{ij} ，求 $M = (I - W)^T(I - W)$ 的特征值和特征向量

例题1

【例题1】基于最大方差准则推导PCA的方法

【解答1】问题是把 D 维数据集 $\{\mathbf{x}_n\}$ 降为1维。定义投影方向为 D 维向量 $\mathbf{u}$ ，且满足 $\mathbf{u}^T \mathbf{u} = 1$ 。

则样本均值为： $\mathbf{u}^T \bar{\mathbf{x}}$ ，样本方差为

$$\frac{1}{N} \sum_{i=1}^N \mathbf{u}^T \mathbf{x}_i - \mathbf{u}^T \bar{\mathbf{x}} = \mathbf{u}^T S \mathbf{u}$$

其中 S 是协方差矩阵。那么优化问题为：

$$\begin{aligned} &\text{maximize } \mathbf{u}^T S \mathbf{u} \\ &s.t. \mathbf{u}^T \mathbf{u} = 1 \end{aligned}$$

利用拉格朗日乘数法，写出其拉格朗日函数：

$$L(\mathbf{u}, \lambda) = \mathbf{u}^T S \mathbf{u} + \lambda(1 - \mathbf{u}^T \mathbf{u})$$

对 $\mathbf{u}$ 求导，并置零，有：

$$S \mathbf{u} = \lambda \mathbf{u}$$

这意味着， λ 是 S 的特征值， $\mathbf{u}$ 是 S 的特征向量。 $\mathbf{u}_1$ 是 S 最大特征值对应的特征向量时，方差取到极大值，称 $\mathbf{u}_1$ 为第一主成分。于是，我们得到利用PCA降维的操作步骤：

1. 计算所有样本点的均值 $\bar{\mathbf{x}}$
2. 对所有样本点进行零均值化： $\mathbf{x}_i = \mathbf{x}_i - \bar{\mathbf{x}}$
3. 计算协方差阵：

$$S = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i^T$$

4. 计算协方差阵的最大的特征值和与其对应的特征向量 $\mathbf{u}$
5. 进行投影： $\mathbf{y} = \mathbf{u}^T \mathbf{x}$

例题2

【例题2】对以下五个二维向量，利用PCA降为一维

$$\boldsymbol{x}_{(1)} = \begin{bmatrix} 2 \\ 5 \end{bmatrix}, \quad \boldsymbol{x}_{(2)} = \begin{bmatrix} 3 \\ 3 \end{bmatrix}, \quad \boldsymbol{x}_{(3)} = \begin{bmatrix} 5 \\ 4 \end{bmatrix}, \quad \boldsymbol{x}_{(4)} = \begin{bmatrix} 4 \\ 6 \end{bmatrix}, \quad \boldsymbol{x}_{(5)} = \begin{bmatrix} 6 \\ 2 \end{bmatrix}$$

【解答2】

1. 计算样本均值：

$$\bar{\boldsymbol{x}} = \begin{bmatrix} 4 \\ 4 \end{bmatrix}$$

2. 零均值化：

$$\boldsymbol{x}_{(1)} = \begin{bmatrix} -2 \\ 1 \end{bmatrix}, \quad \boldsymbol{x}_{(2)} = \begin{bmatrix} -1 \\ -1 \end{bmatrix}, \quad \boldsymbol{x}_{(3)} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \boldsymbol{x}_{(4)} = \begin{bmatrix} 0 \\ 2 \end{bmatrix}, \quad \boldsymbol{x}_{(5)} = \begin{bmatrix} 2 \\ -2 \end{bmatrix}$$

3. 计算协方差矩阵：

$$\boldsymbol{S} = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$$

4. 计算特征值和特征向量：

最大的特征值为 $\lambda = 3$ ，对应的特征向量为：

$$\boldsymbol{u} = \begin{bmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$$

5. 进行投影：

$$\boldsymbol{y} = \boldsymbol{u}^T \boldsymbol{x}$$

详细计算过程：

让我们逐个计算每个向量的外积：

$$1. \mathbf{x}_{(1)}\mathbf{x}_{(1)}^T = \begin{bmatrix} -2 \\ 1 \end{bmatrix} \begin{bmatrix} -2 & 1 \end{bmatrix} = \begin{bmatrix} 4 & -2 \\ -2 & 1 \end{bmatrix}$$

$$2. \mathbf{x}_{(2)}\mathbf{x}_{(2)}^T = \begin{bmatrix} -1 \\ -1 \end{bmatrix} \begin{bmatrix} -1 & -1 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$$

$$3. \mathbf{x}_{(3)}\mathbf{x}_{(3)}^T = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

$$4. \mathbf{x}_{(4)}\mathbf{x}_{(4)}^T = \begin{bmatrix} 0 \\ 2 \end{bmatrix} \begin{bmatrix} 0 & 2 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 4 \end{bmatrix}$$

$$5. \mathbf{x}_{(5)}\mathbf{x}_{(5)}^T = \begin{bmatrix} 2 \\ -2 \end{bmatrix} \begin{bmatrix} 2 & -2 \end{bmatrix} = \begin{bmatrix} 4 & -4 \\ -4 & 4 \end{bmatrix}$$

将这些矩阵相加：

$$\sum = \begin{bmatrix} 4+1+1+0+4 & -2+1+0+0-4 \\ -2+1+0+0-4 & 1+1+0+4+4 \end{bmatrix} = \begin{bmatrix} 10 & -5 \\ -5 & 10 \end{bmatrix}$$

最后除以样本数 $N = 5$ ：

$$S = \frac{1}{5} \begin{bmatrix} 10 & -5 \\ -5 & 10 \end{bmatrix} = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$$

2. 特征值和特征向量的计算

a) 求解特征值：

对于矩阵 $S = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$ ，我们需要解特征方程：

$$|S - \lambda I| = 0$$

其中 I 是单位矩阵。

计算行列式：

$$\begin{vmatrix} 2-\lambda & -1 \\ -1 & 2-\lambda \end{vmatrix} = (2-\lambda)^2 - (-1)(-1) = (2-\lambda)^2 - 1 = 0$$

解方程：

$$\begin{aligned} (2-\lambda)^2 &= 1 \\ 2-\lambda &= \pm 1 \\ \lambda &= 2 \pm 1 \end{aligned}$$

得到两个特征值：

$$\lambda_1 = 3, \quad \lambda_2 = 1$$

b) 求解特征向量：

对于每个特征值，求解 $(S - \lambda I)\mathbf{u} = 0$

对于 $\lambda_1 = 3$ ：

$$(S - 3I)\mathbf{u} = \begin{bmatrix} -1 & -1 \\ -1 & -1 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} = 0$$

这等价于方程： $-u_1 - u_2 = 0$ ，即 $u_1 = -u_2$

取 $u_2 = 1$ ，则 $u_1 = -1$ ，得到向量 $\begin{bmatrix} -1 \\ 1 \end{bmatrix}$

单位化（使其模长为1）：

$$\left\| \begin{bmatrix} -1 \\ 1 \end{bmatrix} \right\| = \sqrt{(-1)^2 + 1^2} = \sqrt{2}$$

单位特征向量为：

$$\mathbf{u}_1 = \begin{bmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$$

对于 $\lambda_2 = 1$ ：

$$(S - I)\mathbf{u} = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} = 0$$

这等价于方程： $u_1 - u_2 = 0$ ，即 $u_1 = u_2$

取 $u_2 = 1$ ，则 $u_1 = 1$ ，得到向量 $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$

单位化：

$$\left\| \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\| = \sqrt{1^2 + 1^2} = \sqrt{2}$$

单位特征向量为：

$$\mathbf{u}_2 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$$

例题3

【例题3】简述PCA和Fisher准则的区别

【解答3】（以下文字是AI生成的）

PCA（主成分分析）和Fisher准则（Fisher线性判别分析）都是降维技术，但它们的目标和方法有所不同：

1. 目标不同：

- **PCA**：主要目的是数据压缩和特征提取，通过正交变换将数据转换到新的坐标系，使得数据的任何投影的第一大方差在第一个坐标（称为第一主成分）上，第二大方差在第二个坐标上，依此类推。PCA不涉及监督学习，即不考虑数据的标签信息。
- **Fisher准则**：是一种监督学习的降维技术，目的是寻找最佳的投影方向，使得不同类别的数据在该方向上的距离尽可能远，而同类数据尽可能近。它利用了数据的类别标签信息。

2. 方法不同：

- **PCA**：通过协方差矩阵的特征值和特征向量来确定主成分，选择的是数据方差最大的方向。
- **Fisher准则**：通过最大化类间散度与类内散度的比值来确定最佳投影方向，选择的是区分不同类别最有效的方向。

3. 应用场景不同：

- **PCA**：适用于无监督学习场景，比如数据压缩、去噪等。
- **Fisher准则**：适用于监督学习场景，尤其是分类问题中的特征提取和降维。

4. 对数据的要求不同：

- **PCA**：对数据的分布没有特别的要求，可以处理各种类型的数据。
- **Fisher准则**：要求数据是分类的，需要知道每个数据点的类别标签。

总结来说，PCA是一种无监督的降维方法，关注于数据的方差；而Fisher准则是一种监督的降维方法，关注于类别的区分度。