

卷积神经网络

仿照生物的视觉感知机制，是一类包含卷积及计算、具有深度结构的前馈神经网络，是深度学习的代表方法之一

- **局部卷积操作**：滑动窗口，边缘填充
- **共享权重参数**：不同位置的局部窗口使用相同的卷积核权重参数
- **多卷积核运算**：为了充分提取特征，可以使用多个卷积核，特征图叠加形成通道
- **池化处理**：对不同空间位置的特征值进行聚合统计
 - 降维
 - 克服过拟合
 - 在图像识别领域，池化可提供平移和旋转不变性
- **多层处理**：单层卷积及池化仅学到局部特征。层数越多，所学特征越全局。通过多层处理，低级特征可以形成更高级特征
 - 由卷积层、子采样层、全连接层交叉堆叠而成，趋向于小卷积、大深度
- **线性整流激活函数**

深度神经网络训练

- **随机梯度下降**：每个训练轮次使用单个样本的梯度进行参数更新
 - 引起梯度震荡、相似样本，冗余计算
- **批梯度下降**：使用所有样本的梯度和进行参数更新
 - 计算量大、易陷入局部极小值
- **小批量梯度下降**：使用一部分样本梯度和进行参数更新
 - 计算小批量数据的梯度更加高效、收敛更稳定、样本使用更灵活
 - 目前最常用的策略。在使用中，这种方法通常被称为SGD

学习率调节

- **自适应学习率**：线性衰减、指数衰减
- **Adagrad**：对稀疏参数进行大幅更新和对频繁参数进行小幅更新、适合处理稀疏数据
- **RMSprop**：用滑动平均代替全局累积梯度平方和，避免学习率过早衰减
- **Adadelta**：使用前一次的梯度开方代替初始学习率
- **动量SGD**：引入动量momentum，抑制梯度的震荡
- **Nesterov梯度**：具有一定的预测性，在计算当前梯度前，先按历史动量更新一次参数
- **Adam**：最常用的方法

训练问题

- **梯度消失**：随着隐含层增加，反向传播传递给较低层的信息会减少。实际上，由于信息向前反馈，不同层间的梯度开始消失，对网络中权重的影响也会变小
- **过度拟合**：模型非常复杂。会导致对训练数据有非常好的识别效果，而对真实样本的识别效果非常差

如何有效训练神经网络

- **线性整流激活函数**：避免了梯度爆炸和梯度消失问题；简化计算过程；训练稀疏网络
- **Dropout机制**：随机关闭一些神经元，避免深度神经网络过拟合，降低模型参数，强制使网络有鲁棒的表示
- **Batch Normalization**：对激活后的输出归一化，可以选择较大的学习率，可以减少或不使用 dropout，缓解梯度消失、爆炸问题
- **残差神经网络**：在输入和输出之间加入"捷径"连接，构造更深的神经网络，易收敛，不退化，Block 内部取消 pooling，用更小的卷积核

循环神经网络

- 既能处理序列输入，也能得到序列输出
- RNN由输入，隐状态、及输出三部分组成
- 当t与k间隔较远时，梯度会很快变的很大或很小

LSTM

- 遗忘门选择哪些信息应该被遗忘
- Cell不断更新新状态并输出

Transformer

传统CNN和RNN存在的问题：

- **长距离依赖问题**：RNN随着序列长度的增加，模型很难捕捉到序列开始和结束之间的依赖关系
- **并行计算问题**：RNN必须按序列顺序逐个处理元素，这限制了训练过程的并行化
- **上下文建模问题**：传统模型如RNN和CNN通常具有固定的窗口或范围来捕捉上下文信息

Transformer网络

- 摒弃循环神经网络：完全依赖注意力机制
- 能够更加高效灵活的建模序列数据

注意力机制

- **查询 (Query)**：查询项，自主提示，即主观意识的特征向量
- **键 (Key)**：被比对项，非自主提示，即物体的突出特征向量
- **值 (Value)**：代表物体本身的特征向量，通常和Key成对出现

计算步骤

1. 查询(query)与键(key)计算注意力评分，通过softmax函数得到不同的显著性值
2. 根据不同的注意力权重，对值(value)进行加权求和

自注意力机制：

- 注意力机制的变体
- 减少对外部信息的依赖，更擅长捕捉数据或特征的内部相关性
- 注意力机制的Query和Key是不同来源的，自注意机制的Query和Key来自同一组的元素

编码器结构

- **自注意力模块**：类似于拆解对照表
- **前馈网络**：根据权重完成一次变形
 - 归一化：稳定反向传播梯度
 - 残差链接：避免梯度消失
 - FFN：已有信息之间的并行融合，总结高级语义特征

编解码注意力机制

- Query和Key来自Encoder输出，Value来自Decoder的上一层

多头注意力机制

- 将查询(Query)、键(Key)和值(Value)通过不同的注意力结构
- 不同注意力头关注的重点不同

输入与位置编码

- **输入编码**：将输入Token序列转为特征序列
- **极位置编码**：引入序列相对位置信息
 - 绝对位置编码：对序列的绝对位置（第几个字符）进行差异化编码
 - 相对位置编码：根据词间的相对位置进行编码
 - 旋转位置编码：实现统一的绝对、相对极位置编码

模型输出层

- 输出通过线性层映射到词表大小
- SoftMax层将向量转化为概率值

模型训练

- 并行训练过程，串行自回归推理

自编码器

- 学习一个输入输出相同的"恒等函数"，无监督
- 只有一个隐含层的时候，其原理相当于主成分分析
- 用于无监督特征提取、图像增强、去噪，数据降维

生成对抗网络

- 生成模型主要步骤：密度估计、采样
- 另一种生成数据的思路：生成对抗
- **生成网络**从潜在空间中随机采样作为输入，其输出结果需要尽量模仿训练集中的真实样本
- **判别网络**的输入则为真实样本或生成网络的输出，其目的是将生成网络的输出从真实样本中尽可能分辨出来

对抗学习

- 生成网络要尽可能地欺骗判别网络
- 判别网络将生成网络生成的样本与真实样本中尽可能区分出来
- 两个网络相互对抗、不断调整参数，最终目的是使判别网络无法判断生成网络的输出结果是否真实