



基本概念

回归属于**监督学习**，其目标是将输入变量分配至由一个或多个**连续变量**组成的输出

数学表示：给定输入数据 x 和一个连续型输出 y ，目标是找到一个函数 $f: x \rightarrow y$ ，使 $f(x)$ 与 y 的差距尽可能小



- 基本形式： $y(x, w) = w^T \phi(x)$
- 目标函数（代价函数、损失函数）： $J(w) = \frac{1}{2} \sum_{i=1}^N (f(x_i) - y_i)^2$

标准方程组

直接求导得到极值

- 矩阵形式的目标函数

$$J(\mathbf{w}) = \sum_{i=1}^N (\mathbf{w}^T \mathbf{x}_i - y_i)^2 = (\mathbf{X}\mathbf{w} - \mathbf{y})^T (\mathbf{X}\mathbf{w} - \mathbf{y})$$

- 关键矩阵定义

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_N^T \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1m} \\ x_{21} & \cdots & x_{2m} \\ \vdots & \ddots & \vdots \\ x_{N1} & \cdots & x_{Nm} \end{pmatrix}$$

$$\mathbf{y} = (y_1 \quad y_2 \quad \cdots \quad y_N)^T$$

- 求导

$$\frac{\partial}{\partial \mathbf{w}} J(\mathbf{w}) = 2\mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{y}) = 0$$

$$\mathbf{X}^T \mathbf{X} \mathbf{w} = \mathbf{X}^T \mathbf{y}$$

- 得到模型参数

$$\hat{\mathbf{w}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

梯度下降

梯度下降法是一个最优化算法，是求解无约束优化问题最简单和最基础的方法之一。以负梯度方向为搜索方向，越接近目标值，步长越小，前进越慢

- 给定初始参数值 w^0
- 通过更新 w 使损失函数 $J(w)$ 逐步减小
 - $w_j^t = w_j^{t-1} - \alpha \frac{\partial}{\partial w_j} J(w)$
 - $\frac{\partial}{\partial w_j} J(w) = \sum_{i=1}^N (f(x_i) - y_i) \cdot x_{i,j}$
 - $f(x_i) = [w^{t-1}]^T x_i$
- α 为学习率或更新步长

批处理梯度下降

在梯度下降方法中，每次更新都利用所有数据，对于凸函数，可以达到全局最优，在大样本条件下，批处理梯度下降的迭代速度很慢

$$w_j^t = w_j^{t-1} - \alpha \sum_{i=1}^N (f(\mathbf{x}_i) - y_i) \cdot x_{i,j}$$

批梯度下降计算量大，且易于陷入局部最小值

随机梯度下降

每次只用一个样本，收敛速度较快，对大样本数据较有效，对于更复杂的优化目标，可以跳出局部最优解

$$w_j^t = w_j^{t-1} - \alpha (f(\mathbf{x}_r) - y_r) \cdot x_{r,j}$$

随机梯度下降可能引起梯度震荡，且相似样本会冗余计算

与标准方程组相比

方法	特点	适用情况
梯度下降法	需要选择 α 需要迭代多次 需要数据归一化 样本量非常大时也适用	样本量较大时
标准方程组	不需要选择 α 不需要迭代多次 无需数据归一化 样本量大时不适用（需要计算 $(XX^T)^{-1}$ ）	样本量较小时

线性判别函数

概念

将分类器设计问题转化为求准则函数极值的问题


两类情况下的判别函数 $g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$

- $\mathbf{x} = [x_1, x_2, \dots, x_d]^T$: d 维特征向量
- $\mathbf{w} = [w_1, w_2, \dots, w_d]^T$: 权向量
- w_0 : 阈值权（常数项）

$$\begin{cases} g(\mathbf{x}) > 0 & \Rightarrow \mathbf{x} \in \omega_1 \\ g(\mathbf{x}) < 0 & \Rightarrow \mathbf{x} \in \omega_2 \\ g(\mathbf{x}) = 0 & \text{可任意分类或拒绝} \end{cases}$$

- 当 $g(\mathbf{x})$ 为线性函数时，决策面是 d 维空间中的超平面

意义



- 若 $\mathbf{x}$ 为原点，则 $g(\mathbf{x}) = w_0$
- 从原点到超平面 H 的距离 $r_0 = \frac{w_0}{\|\mathbf{w}\|}$

- 如果 $w_0 > 0$, 则原点在H的正侧
如果 $w_0 < 0$, 则原点在H的负侧
如果 $w_0 = 0$, 则 $g(x)$ 具有齐次形式, 超平面H通过原点
- 超平面H的方向由权向量 w 决定; 其位置由阈值权 w_0 确定
- 判别函数 $g(x)$ 正比于 x 点到超平面的代数距离
- 当 x 在H的正侧时, $g(x) > 0$
当 x 在H的负侧时, $g(x) < 0$

齐次化

- 线性判别函数表达式: $g(x) = w^T x + w_0$
- 齐次简化形式: $g(x) = a^T y$
- $y = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix} = \begin{bmatrix} 1 \\ x \end{bmatrix} \quad a = \begin{bmatrix} 1 \\ w_1 \\ w_2 \\ \vdots \\ w_d \end{bmatrix} = \begin{bmatrix} w_0 \\ w \end{bmatrix}$
- 维度变换: $\hat{d} = d + 1$ (y 比 x 增加一维)
 - 保持样本空间欧式距离不变
 - 变换后样本仍位于原 d 维子空间 (X 空间)
- 超平面方程: $a^T y = 0$ 在 Y 空间定义通过原点的超平面 $\hat{H}$
 - $\hat{H}$ 对 d 维子空间的划分
 - 与原决策面 $w^T x + w_0 = 0$ 对 X 空间的划分完全相同
- 距离公式: $r = \frac{g(x)}{\|a\|} = \frac{a^T y}{\|a\|}$

广义线性判别函数

利用线性函数的简单性解决复杂问题, 但维数大大增加, 不适用于非凸和多连通区域划分

分类器设计

将分类器设计转化为准则函数极值问题 (w^* , w_0^* 或 a^*)

- 样本准备: 使用带类别标签的样本集 $\mathcal{X} = \{x_1, \dots, x_N\}$ 或其增广集 $\mathcal{Y}$
- 准则函数 $\mathcal{T}$ 需满足:
 - 是样本集和 $w/w_0/a$ 的函数
 - 极值对应最优分类性能
- 优化求解: 计算准则函数极值 $w^*/w_0^*/a^*$

准则函数

Fisher准则 (LDA算法)

- 考虑把d维空间的样本投影到一条直线上形成一维空间。在一般情况下总可以找到某个方向，使样本在这个方向的直线上的投影分开得最好。Fisher准则就是要解决如何根据实际情况找到这条最好的、最易于分类的投影线的问题
- 希望投影后在一维Y空间中各类样本尽可能分开，即两类均值之差越大越好；同时希望各类样本内部尽量密集，即类内离散度越小越好
- 以二分类问题为例，d维样本 $x_1, x_2, \dots, x_N$
 - N_1 个属于 ω_1 类记为子集 X_1 ， N_2 个属于 ω_2 类记为子集 X_2
 - $m_i = \frac{1}{N_i} \sum_{x \in X_i} x, \quad i = 1, 2$
 - 类内离散度矩阵： $S_i = \sum_{x \in X_i} (x - m_i)(x - m_i)^T, \quad i = 1, 2$
 - 总类内离散度矩阵： $S_w = S_1 + S_2$
- Fisher准则函数 $J_F(w) = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{S_1^2 + S_2^2} = \frac{w^T S_b w}{w^T S_w w}$
- $w^* = S_w^{-1}(m_1 - m_2)$ ，使得 $J_F(w)$ 最大化

感知器准则

对随意给定的判别函数初始值，通过样本分类训练过程逐步对其修正直至最终确定，本质上也是一个线性分类函数，学习目标是生成一个线性分类器。

- 损失函数：** $J_P(a) = \sum_{y \in \eta^k} (-a^T y)$
 - 衡量当前判别函数 a 对误分类样本集 η^k 的分类错误程度
 - 通过误分类样本的负线性组合来惩罚分类错误
- 梯度：** $\nabla J_P(a) = \frac{\partial J_P(a)}{\partial a} = \sum_{y \in \eta^k} (-y)$
 - 表示损失函数关于参数 a 的变化率，指向使损失函数增加最快的方向
 - 梯度计算仅依赖于误分类样本，正确分类的样本不贡献梯度
- 更新公式：** $a(k+1) = a(k) - \rho_k \nabla J = a(k) + \rho_k \sum_{y \in \eta^k} y$
 - 通过不断迭代更新参数 a 来最小化损失函数
 - 学习率 ρ_k 控制每次更新的步长，通常随着迭代逐渐减小
- 局限性：**
 - 结果不唯一：不同的初始值和更新顺序可能导致不同的解
 - 在线性不可分情况下不收敛：当数据无法被超平面完美分割时，算法会持续振荡

最小二乘准则

- 方程形式：** $a^T y_n = b_n > 0 \Rightarrow Y a = b$
 - 定义了线性关系，将分类问题转化为线性方程组求解
- 损失函数：** $J_s(a) = \|e\|^2 = \|Y a - b\|^2 = \sum_{n=1}^N (a^T y_n - b_n)^2$
 - 衡量预测值与目标值之间的平方误差
 - 通过最小化平方误差来寻找最优参数
- 最优解：** $a^* = (Y^T Y)^{-1} Y^T b = Y^+ b$

- 在 $Y^T Y$ 可逆的条件下得到解析解
- 使用伪逆 Y^+ 可在 $Y^T Y$ 奇异时仍求得解
- **特殊取值意义：**
 - 当 b 各维度依次取 N_i 个 $\frac{N}{N_i}$ 时，等价于Fisher解
 - 当 b 各维度取1时，以最小均方误差逼近贝叶斯判别函数
- **局限性：**
 - 要求 $Y^T Y$ 非奇异，否则需要正则化或伪逆
 - 计算量大，特别是高维情况下矩阵求逆计算复杂
 - 对异常值非常敏感，平方误差会放大异常点的影响
- **梯度下降求解：**
 - $\nabla J_s(a) = 2Y^T(Ya - b)$
 - $a(k+1) = a(k) - \rho_k Y^T(Ya - b)$
 - 迭代更新避免直接求逆，适用于大规模数据

例题1

Fisher准则

给定两类2维数据:

- ω_1 类: $X_1 = \{(1,2), (2,3), (2,1)\}$
- ω_2 类: $X_2 = \{(4,5), (5,4), (6,5)\}$

求解步骤

1. 计算均值向量

$$m_1 = \frac{1}{3} \left(\begin{bmatrix} 1 \\ 2 \end{bmatrix} + \begin{bmatrix} 2 \\ 3 \end{bmatrix} + \begin{bmatrix} 2 \\ 1 \end{bmatrix} \right) = \begin{bmatrix} 5/3 \\ 2 \end{bmatrix}$$
$$m_2 = \frac{1}{3} \left(\begin{bmatrix} 4 \\ 5 \end{bmatrix} + \begin{bmatrix} 5 \\ 4 \end{bmatrix} + \begin{bmatrix} 6 \\ 5 \end{bmatrix} \right) = \begin{bmatrix} 5 \\ 14/3 \end{bmatrix}$$

2. 计算类内离散度矩阵

$$S_1 = \begin{bmatrix} 2/3 & -2/3 \\ -2/3 & 2 \end{bmatrix}, \quad S_2 = \begin{bmatrix} 2 & -2/3 \\ -2/3 & 2/3 \end{bmatrix}$$
$$S_w = S_1 + S_2 = \begin{bmatrix} 8/3 & -4/3 \\ -4/3 & 8/3 \end{bmatrix}$$

3. 求最优投影方向

$$w^* = S_w^{-1}(m_1 - m_2) = \begin{bmatrix} 0.5 & 0.25 \\ 0.25 & 0.5 \end{bmatrix} \begin{bmatrix} -10/3 \\ -8/3 \end{bmatrix} = \begin{bmatrix} -7/3 \\ -13/6 \end{bmatrix}$$

4. Fisher准则值

$$J_F(w^*) = \frac{w^{*T} S_b w^*}{w^{*T} S_w w^*} \approx 8.45$$

例题2

感知器准则

【讲解】问题的格式是：现有样本集 $\{x_1, \dots, x_n\}$ 属于 w_1, w_2 两类，寻找向量 a ，使得： $\forall x \in w_1, a^T x > 0$ ，且 $\forall x \in w_2, a^T x < 0$ 。即使用一个仿射流形把样本分成两半，这时称样本是线性可分的。其具体操作步骤是：

1. 构造规范化增广样本向量。

这一步的关键是增广和规范化。因为一般线性流形的表达式是 $w^T x + b$ ，但是我们要把这个 b 包含在 w 里面，就要把样本进行增广。增广的操作步骤是给样本的坐标前面补充1个1。

规范化的意思是，如果样本是正例（属于 w_1 ），就保持不变；否则，它的每个坐标都变成相反数。

规范化增广样本向量记作 $\{y_1 \dots y_n\}$

2. 在 y 集合上循环迭代：对于每个 y_i ，计算 $a_k^T y_i$ ，如果 $a_k^T y_i \leq 0$ ，则 $a_{k+1} = a_k + y_i$ ；否则， $a_{k+1} = a_k$ 。直到对于某个 a ，所有的 y 都满足 $a^T y > 0$ ，那么这就是最终结果。

这实际上是梯度下降法的过程，推导略。

【例子】现有数据集：

1. 类别1: $x_1^T = (-2, 2)$, $x_2^T = (-2, -2)$

2. 类别2: $x_3^T = (2, 1)$, $x_4^T = (2, -1)$

初始化权: $a_0^T = (0, 2, 1)$ ，利用感知机准则求判别函数。

【解答】

1. 构造规范化增广样本向量：

$$y_1^T = (1, -2, 2), y_2^T = (1, -2, -2)$$

$$y_3^T = (-1, -2, -1), y_4^T = (-1, -2, 1)$$

2. 迭代

$$\text{i. } a_1^T y_1 = (0, 2, 1) \cdot (1, -2, 2)^T = -2 < 0, \quad a_2 = a_1 + y_1 = (1, 0, 3)$$

$$\text{ii. } a_2^T y_2 = (1, 0, 3) \cdot (1, -2, -2)^T = -1 < 0, \quad a_3 = a_2 + y_2 = (2, -2, 1)$$

$$\text{iii. } a_3^T y_3 = (2, -2, 1) \cdot (-1, -2, -1)^T = 1 > 0, \quad a_4 = a_3$$

$$\text{iv. } a_4^T y_4 = (2, -2, 1) \cdot (-1, -2, 1)^T = 3 > 0, \quad a_5 = a_4$$

$$\text{v. } a_5^T y_1 = (2, -2, 1) \cdot (1, -2, 2)^T = 8 > 0, \quad a_6 = a_5$$

$$\text{vi. } a_6^T y_2 = (2, -2, 1) \cdot (1, -2, -2)^T = 4 > 0, \quad a_6 = a_5$$

至此，对于 $a^T = (2, -2, 1)$ ，所有的 y 都满足 $a^T y > 0$ ，那么这就是最终结果。