

聚类

聚类是将数据集中的样本划分为若干个不相交的子集，每个子集称为一个簇，使得同一簇内的样本具有较高的相似度，不同簇的样本具有较大的差异性。聚类是一种**无监督学习方法**，不需要预先标记的训练数据，而是通过数据本身的特征来发现内在的分组结构。

性能度量

样本对数量定义

- **a:** 真实标签相同（属于同一真实类别），且聚类预测标签也相同（被聚为同一类）的样本对数量
- **b:** 真实标签相同（属于同一真实类别），但聚类预测标签不同（被分成不同类）的样本对数量
- **c:** 真实标签不同（属于不同真实类别），但聚类预测标签相同（被合并为同一类）的样本对数量
- **d:** 真实标签不同（属于不同真实类别），且聚类预测标签也不同（被分成不同类）的样本对数量

外部指标

将聚类结果与某个"参考模型"进行比较

- **Jaccard系数:** $JC = \frac{a}{a+b+c}$
- **FMI指数:** $FMI = \sqrt{\frac{a}{a+b} \cdot \frac{a}{a+c}}$
- **Rand指数:** $RI = \frac{2(a+b)}{m(m-1)}$

内部指标

直接考察聚类结果而不用任何参考模型

- **簇C内样本间的平均距离:** $avg(C) = \frac{2}{|C|(|C|-1)} \sum_{1 \leq i \leq j \leq |C|} dist(x_i, x_j)$
- **簇C内样本间的最远距离 (直径):** $diam(C) = \max_{1 \leq i \leq j \leq |C|} dist(x_i, x_j)$
- **簇 C_i 与簇 C_j 最近样本间的距离:** $d_{\min}(C_i, C_j) = \min_{x_i \in C_i, x_j \in C_j} dist(x_i, x_j)$
- **簇 C_i 与簇 C_j 中心点间的距离 (其中 $\mu_k = \frac{1}{|C_k|} \sum_{1 \leq i \leq |C_k|} x_i$ 为簇 C_k 的中心):**
 $d_{\text{cen}}(C_i, C_j) = dist(\mu_i, \mu_j)$
- **DB指数:** $DBI = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{avg(C_i) + avg(C_j)}{d_{\text{cen}}(\mu_i, \mu_j)} \right)$
- **Dunn指数:** $DI = \min_{1 \leq i \leq k} \left\{ \min_{j \neq i} \left(\frac{d_{\min}(C_i, C_j)}{\max_{1 \leq i \leq k} diam(C_i)} \right) \right\}$

K均值算法

算法原理

输入: 样本集 $D = \{x_1, x_2, \dots, x_m\}$;
聚类簇数 k .

过程:

```
1: 从  $D$  中随机选择  $k$  个样本作为初始均值向量  $\{\mu_1, \mu_2, \dots, \mu_k\}$ 
2: repeat
3:   令  $C_i = \emptyset$  ( $1 \leq i \leq k$ )
4:   for  $j = 1, \dots, m$  do
5:     计算样本  $x_j$  与各均值向量  $\mu_i$  ( $1 \leq i \leq k$ ) 的距离:  $d_{ji} = \|x_j - \mu_i\|_2$ ;
6:     根据距离最近的均值向量确定  $x_j$  的簇标记:  $\lambda_j = \arg \min_{i \in \{1, 2, \dots, k\}} d_{ji}$ 
7:     将样本  $x_j$  划入相应的簇:  $C_{\lambda_j} = C_{\lambda_j} \cup \{x_j\}$ ;
8:   end for
9:   for  $i = 1, \dots, k$  do
10:    计算新均值向量:  $\mu'_i = \frac{1}{|C_i|} \sum_{x \in C_i} x$ ;
11:    if  $\mu'_i \neq \mu_i$  then
12:      将当前均值向量  $\mu_i$  更新为  $\mu'_i$ 
13:    else
14:      保持当前均值向量不变
15:    end if
16:  end for
17: until 当前均值向量均未更新
18: return 簇划分结果
```

输出: 簇划分 $\mathcal{C} = \{C_1, C_2, \dots, C_k\}$

- **最小化准则函数:** $E = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|_2^2$, 其中, μ_i 是簇 C_i 的均值向量, E 刻画簇内样本围绕簇均值的紧密程度, E 越小, 簇内样本相似度越高
- **初始化选择 K 个初始聚类中心**
- 将每个数据点划分给最近的聚类中心 μ_k , 得到聚类标注 r_n
- 最小化准则函数, 重新计算均值向量, 作为聚类中心 μ_k , 直到均值向量不变

缺点

1. **对初始聚类中心敏感:** 不同的初始中心选择可能导致完全不同的聚类结果
2. **需要预先指定聚类数量 K :** 在实际应用中, K 值往往难以确定
3. **对噪声和异常值敏感:** 异常值会严重影响聚类中心的计算
4. **只能发现球形簇:** 对于非球形或复杂形状的簇效果不佳
5. **容易陷入局部最优:** 可能无法找到全局最优的聚类结果
6. **大规模数据集上计算效率较低**

K-means改进

Kmeans++

在选取第 $n + 1$ 个中心时: 距离当前 n 个聚类中心越远的点会有更高的概率被选为第 $n + 1$ 个聚类中心, 即聚类中心离得越远越好

Kernel Kmeans

参照支持向量机中核函数的思想，将所有样本映射到另外一个特征空间中再进行聚类

迭代自组织数据分析算法

在K均值算法的基础上，增加对聚类结果的"合并"和"分裂"两个操作，并设定算法运行控制参数的一种聚类算法，通过设定初始参数而引入人的决策，当某两类聚类中心距离小于某阈值时，将它们合并为一类，当某类标准差大于某一阈值或其样本数目超过某阈值时，将其分裂为两类。在某类样本数目少于某阈值时，需将其取消

层次聚类算法

试图在不同层次对数据集进行划分，从而形成树形的聚类结构，数据集划分既可采用"自底向上"的聚合策略，也可采用"自顶向下"的分拆策略

- **AGNES算法:** 自底向上的层次聚类算法。首先，将样本中的每个样本看做一个初始聚类簇，然后在算法运行的每一步中找出距离最近的两个聚类簇进行合并，该过程不断重复，直到达到预设的聚类簇的个数

输入: 样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$;
聚类簇距离度量函数 $d \in \{d_{\min}, d_{\max}, d_{\text{avg}}\}$;
聚类簇数 k .

过程:

```
1: for  $j = 1, \dots, m$  do
2:    $C_j = \{\mathbf{x}_j\}$ 
3: end for
4: for  $i = 1, \dots, m$  do
5:   for  $j = i, \dots, m$  do
6:      $M(i, j) = d(C_i, C_j)$ ;
7:      $M(j, i) = M(i, j)$ 
8:   end for
9: end for
10: 设置当前聚类簇个数:  $q = m$ 
11: while  $q > k$  do
12:   找出距离最近的两个聚类簇( $C_{i^*}, C_{j^*}$ );
13:   合并( $C_{i^*}, C_{j^*}$ ):  $C_{i^*} = C_{i^*} \cup C_{j^*}$ ;
14:   for  $j = j^* + 1, \dots, q$  do
15:     将聚类簇  $C_j$  重编号为  $C_{j-1}$ 
16:   end for
17:   删除距离矩阵  $M$  的第  $j^*$  行与第  $j^*$  列;
18:   for  $j = 1, \dots, q - 1$  do
19:      $M(i^*, j) = d(C_{i^*}, C_j)$ ;
20:      $M(j, i^*) = M(i^*, j)$ 
21:   end for
22:    $q = q - 1$ 
23: end while
24: return 簇划分结果
```

输出: 簇划分 $\mathcal{C} = \{C_1, C_2, \dots, C_k\}$

例题

【讲解】一般都是考概念题，问你K均值算法、高斯混合模型、EM算法分别是什么，有什么改进空间等。

K均值算法

定义：给定 D 维空间上的数据集 $X = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ ，这些数据对应类别未知。K均值算法将数据集划分成 K 类，各类的聚类中心记为 $\mu_1, \dots, \mu_k$ ，并将每一个样本 $\mathbf{x}_n$ 划归到离该样本最近的聚类中心。

K均值算法的一般流程

1. 初始化选择K个初始聚类中心
2. 将每个数据点划分给最近的聚类中心 μ_k ，得到聚类标注 r_n
3. 最小化准则函数，重新计算聚类中心 μ_k 。求解方法：对 μ_k 求导并置零。

$$J = \sum_{n=1}^N \sum_{k=1}^K r_{nk} \|\mathbf{x}_n - \mu_k\|^2$$

求导：

$$2 \sum_{n=1}^N r_{nk} (\mathbf{x}_n - \mu_k) = 0$$

求解：

$$\mu_k = \frac{\sum_n r_{nk} \mathbf{x}_n}{\sum_n r_{nk}}$$

4. 迭代步骤2和3，直到满足终止条件：聚类中心不再发生显著变化或达到最大迭代次数