

基本概念

集成学习通过构建并结合多个学习器完成学习任务，也称为多分类器系统。通过将多个学习器进行集成，常可获得比单一学习器显著优越的泛化性能，这对弱学习器尤为明显。

- **弱学习器**：准确率仅比随机猜测略高的学习器，其训练通常更简单，容易得到
- **强学习器**：准确率高并能在多项式时间内完成的学习器，其训练往往非常复杂，不容易得到
- **收敛特性**：在一定条件下，随着集成分类器数目的增加，集成的错误率将指数级下降，最终趋向于0

多样性度量

用于度量集成中个体学习器的多样性，考虑个体学习器的两两相似/不相似性。

混淆矩阵表示

	$h_j = +1$	$h_j = -1$
$h_i = +1$	a	c
$h_i = -1$	b	d

其中， $a + b + c + d = m$

度量方法

- **不合度量**： $dis_{ij} = \frac{b+c}{m}$ ，值域[0,1]，值越大多样性越大
- **相关系数**： $\rho_{ij} = \frac{ad-bc}{\sqrt{(a+b)(a+c)(c+d)(b+d)}}$ ，值域[-1,1]，学习器无关值为0；正相关值为正，否则为负
- **Q-统计量**： $Q_{ij} = \frac{ad-bc}{ad+bc}$ ， Q_{ij} 与相关系数 ρ_{ij} 符号相同，且 $|Q_{ij}| \leq |\rho_{ij}|$
- **k统计量**： $k = \frac{p_1 - p_2}{1 - p_2}$
 - p_1 ： $h_i h_j$ 一致概率， $p_1 = \frac{a+d}{m}$
 - p_2 ： $h_i h_j$ 偶然一致概率（ $h_i h_j$ 独立）， $p_2 = \frac{(a+b)(a+c) + (c+d)(b+d)}{m^2}$
 - 通常非负，学习器完全一致时值为1；偶然一致时值为0，一致概率低于偶然时取负值

多样性增强

在学习过程引入随机性来增强多样性。

数据样本扰动

通常是基于采样法：

- Bagging中的自助采样
- Adaboost中的序列采样
- 对数据样本扰动敏感的基学习器（不稳定基学习器）效果明显，如决策树、神经网络

- 对数据样本扰动不敏感的基学习器（稳定基学习器）效果不明显，如线性学习器，支持向量机，朴素贝叶斯，K近邻等

输入属性扰动

不同子空间提供观察数据的不同视角：

- 对包含大量冗余属性数据，可产生多样性大的个体学习器，还因属性数减少会大幅节省时间开销
- 若数据只含少量属性或冗余属性较少，则不宜使用

输出表示扰动

操纵输出表示：

- **翻转法**：对训练样本的类标记稍作变动，随机改变一些训练样本的标记（噪声，增强模型泛化性）
- **输出调制法**：对输出表示进行转化，将分类输出转为回归输出构建个体学习器
- **ECOC法**：将原任务拆解为多个可同时求解的子任务，利用纠错输出码将多分类任务拆解为一系列二分类任务训练基学习器

算法参数扰动

随机设置不同的参数或环节：

- **参数较多时**：负相关法，显式地通过正则化项强制个体神经网络使用不同参数
- **参数较少时**：例如将决策树使用的属性选择机制用其他类似方式代替，信息增益、信息增益率、基尼指数等

组合应用

不同的多样性增强机制也可一起使用：

- Adaboost：加入了数据样本扰动
- 随机森林：同时加入了数据样本扰动和输入属性扰动
- 单一学习器利用交叉验证对参数寻优，事实上相当于使用了不同参数训练学习器，最后仅选择了一个；而集成学习相当于把所有学习器都利用起来

集成学习的优点

- **统计方面**：减小误选假设空间导致泛化性能不佳的几率
- **计算方面**：降低陷入坏局部极小点影响泛化性能的风险
- **表示方面**：扩大假设空间(域)学习对于真实空间更好近似

组合策略

平均法

数值型输出最常见的结合策略：

- **简单平均法**：个体学习器性能相近时适用
- **加权平均法**：个体学习器性能迥异时适用

- **基本出发点**：加权平均法是集成学习的基本出发点，各种结合方法都可视为其特例或变体，不同的集成学习方法是通过对不同的方式确定加权平均法中基学习器的权重

投票法

标签型输出最常见的结合策略，分为硬投票(类标签)和软投票(类概率)：

- **绝对多数投票法**：得票超半数
- **相对多数投票法**：得票最多
- **加权投票法**：加权后得票最多

学习法

当训练数据很多时采用另一个学习器进行结合：

- 从初始数据集训练初级学习器，生成次级数据集：初级学习器的输出被当作样例输入特征，继承初始样本标记从次级数据集训练次级学习器

学习方法

串行化方法

个体学习器间存在强依赖关系：

提升 Boosting 算法：一族可将弱学习器提升为强学习器的算法

- 每次调整训练数据的样本分布
- 先从初始数据集训练一个基学习器，再根据其对训练样本分布(权重)进行调整，使先前错分样本在后续受到更多关注，然后基于调整后的样本分布训练下一个基学习器重复进行直至基学习器数目达到预先指定值；最终将这些基学习器加权结合
- **重赋权法**：在每轮根据样本分布为每个训练样本重新赋予权重
- **重采样法**：在每轮根据样本分布对训练集重新采样形成新的训练集
- Boosting 每轮检查当前生成的基学习器是否满足优于随机猜测的基本条件，若不满足，此基学习器被抛弃，学习过程停止

算法特性：

- 基本思想是用贪心法最小化损失函数
- 主要关注降低偏差：顺序串行地最小化损失函数，基于弱学习器逐步构造出很强的集成学习器 bias 自然逐步下降
- 但是由于模型的相关性很强，因此不能显著降低方差，主要靠降低偏差来提升预测精度
- 基学习器特点：高偏差、低方差的弱模型

并行化方法

个体学习器间不存在强依赖关系：

装袋 Bagging 算法

- 利用自助法采样(Bootstrap)可构造 T 个含 m 个训练样本的采样集，基于每个采样集训练出一个基学习器，再将它们进行结合
- 在对预测输出结合时，通常对分类任务使用简单投票法，对回归任务使用简单平均法

- 时间复杂度低：集成与直接训练一个学习器复杂度同阶

Bagging 特性：

- **可包外估计泛化性能**：将从未被采样过的样本作为测试集
- **主要关注降低方差**：通过多次重复训练提高稳定性，在易受样本扰动的学习器上效用更为明显，如不剪枝的决策树、神经网络等
- **偏差方差特性**：在Bagging中每个模型的偏差方差近似相同，但是互相相关性不太高，因此一般不能降低偏差
- **鲁棒性**：对噪声数据相对鲁棒
- **基学习器特点**：低偏差、高方差，通常用强学习器

随机森林

Bagging方法的一种扩展变体，以决策树为基学习器：

随机性实现：

- **数据集的随机选择**：自助采样法
- **待选属性的随机选择**：对基决策树的每个结点，先从该结点的d个属性集合中随机选择一个包含k个属性的子集，再从这个子集选择一个最优属性用于划分，一般情况下推荐 $k=\log_2 d$

结果处理：

- 最后如果是分类问题，则按照投票的方式选取票数最多的类作为结果返回
- 如果是回归问题，则按照平均法选取所有决策树预测的平均值作为结果返回

算法优势：

- 基学习器多样性通过样本扰动和属性扰动实现
- 算法简单、容易实现、计算开销小，训练效率优于Bagging
- 性能强大，被誉为"代表集成学习技术水平的方法"

例题

【例题】简述集成学习的基本思想，简述Boosting和Bagging的原理和区别

【解答】集成学习的基本思想是通过多个学习器进行集成，可以获得比单一学习器更优的泛化性能。其关键是如何产生「好而不同」的个体学习器。

Boosting是串行方法，即先训练一个学习器，然后对训练集的样本分布进行调整，使得先前错分的样本的权重增加，然后以新的训练集训练新的学习器。如此重复，直到获得够多的学习器，然后进行加权组合。其特点有：

1. 弱模型、偏差高、方差低
2. 个体学习器之间有强依赖，串行生成
3. 不能显著降低方差。

Bagging是并行方法，基于自主采样法，构造 T 个含 m 个样本的采样集，基于每个采样集训练一个学习器。其特点有：方差低、易于并行、无法降低偏差。